# Laboratório 9

Alessandro Silva - Ra 236928

```
import numpy as np
import pandas as pd
from plotnine import *

try:
    from plotnine.data import diamonds
except Exception:
    diamonds = pd.read_csv("diamonds.csv")
    diamonds["cut"] = pd.Categorical(diamonds["cut"], ["Fair","Good","Very Good","Premium","I
    diamonds["color"] = pd.Categorical(diamonds["color"], list("DEFGHIJ"), ordered=True)
    diamonds["clarity"] = pd.Categorical(diamonds["clarity"], ["I1","SI2","SI1","VS2","VS1","

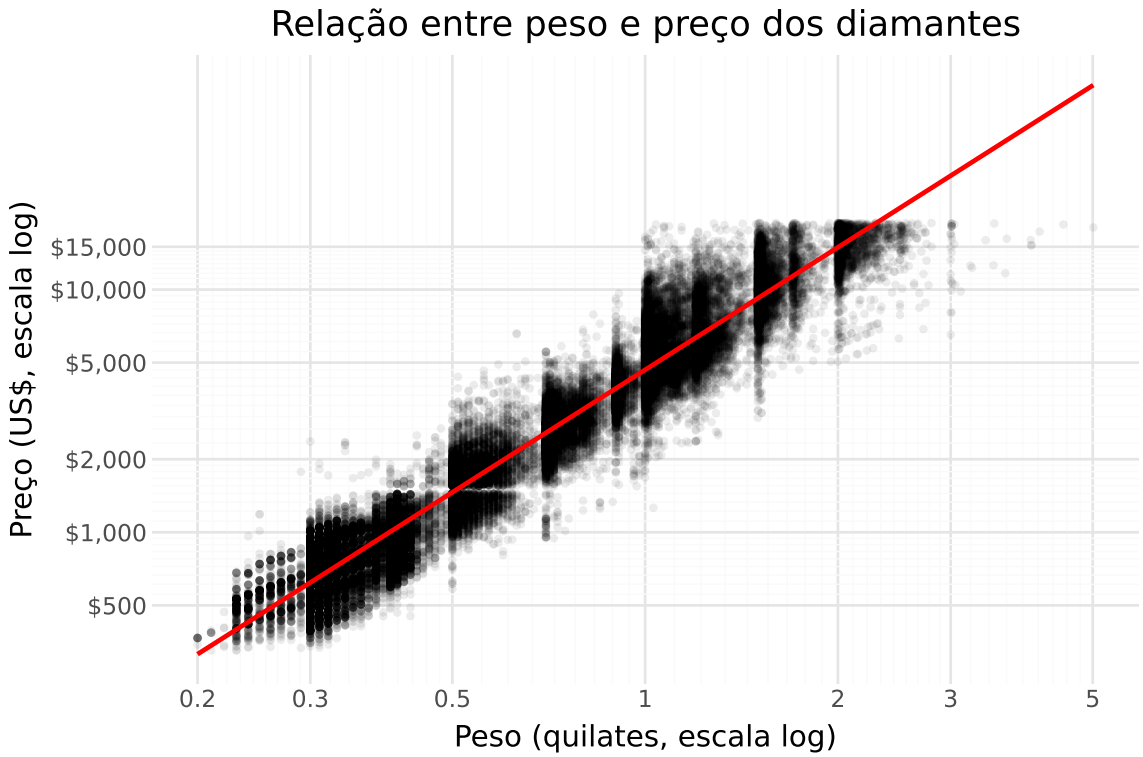
print(diamonds.shape)
diamonds.head()
```

```
(53940, 10)
```

| | carat | cut | color | clarity | depth | table | price | x | y | z |
|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 0.23 | Ideal | E | SI2 | 61.5 | 55.0 | 326 | 3.95 | 3.98 | 2.43 |
| 1 | 0.21 | Premium | E | SI1 | 59.8 | 61.0 | 326 | 3.89 | 3.84 | 2.31 |
| 2 | 0.23 | Good | E | VS1 | 56.9 | 65.0 | 327 | 4.05 | 4.07 | 2.31 |
| 3 | 0.29 | Premium | I | VS2 | 62.4 | 58.0 | 334 | 4.20 | 4.23 | 2.63 |
| 4 | 0.31 | Good | J | SI2 | 63.3 | 58.0 | 335 | 4.34 | 4.35 | 2.75 |

## Questão 1

```
(
    ggplot(diamonds, aes("carat", "price"))
    + geom_point(alpha=0.08, size=0.8)
    + geom_smooth(method="lm", color="red")
    + scale_x_log10(breaks=[0.2, 0.3, 0.5, 1, 2, 3, 5])
    + scale_y_log10(breaks=[500, 1000, 2000, 5000, 10000, 15000],
                    labels=lambda l: ["${:,.0f}".format(v) for v in l])
    + labs(x="Peso (quilates, escala log)", y="Preço (US$, escala log)",
           title="Relação entre peso e preço dos diamantes")
    + theme_minimal()
    + theme(figure_size=(6, 4))
)
```

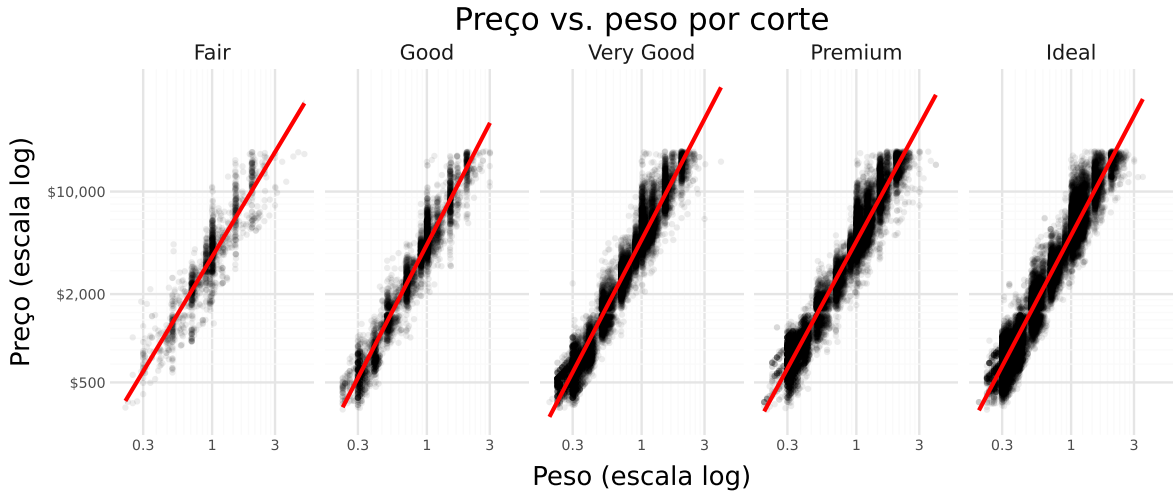



usei transparência nos pontos para reduzir a sobreposição, escalas logarítmicas nos dois eixos (a relação é curva e a variância cresce com o peso), reta de regressão para resumir a tendência, rótulos com unidades e tema limpo.

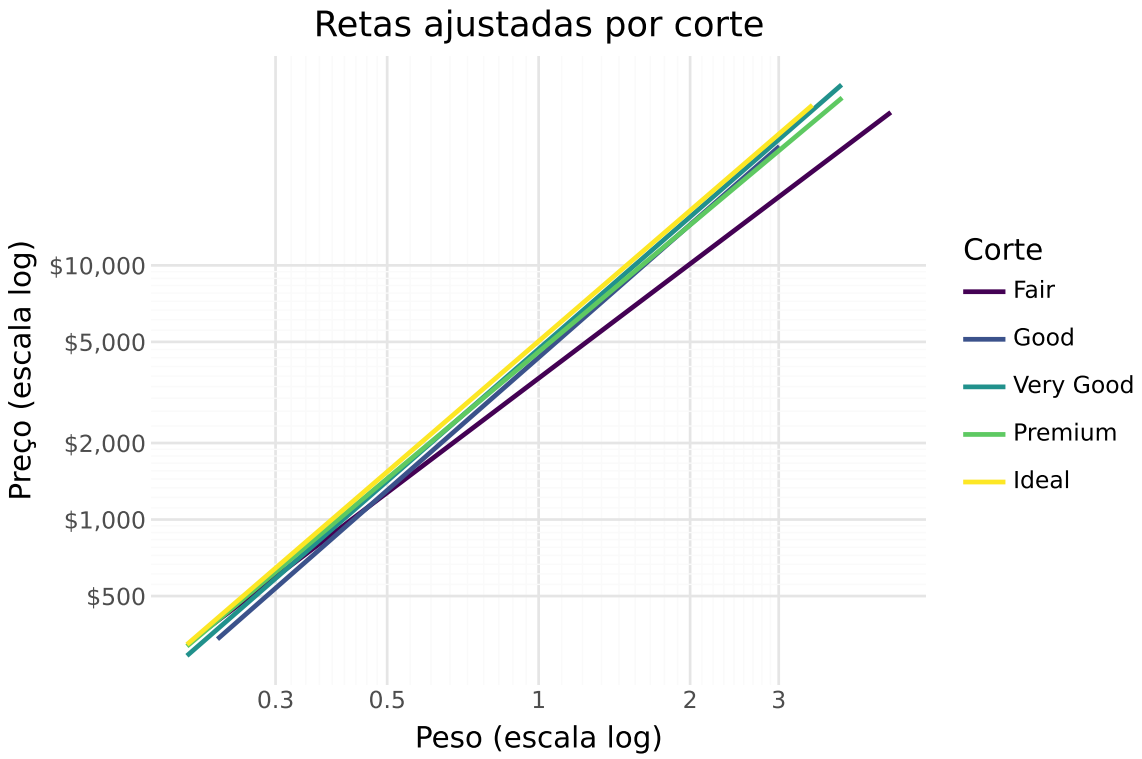
há associação positiva e forte entre peso e preço. Na escala original a relação é não linear, mas em escala log-log fica aproximadamente linear. Para um mesmo peso o preço ainda varia bastante, o que sugere influência de outras características (corte, cor e clareza).

## Questão 2

```
(
    ggplot(diamonds, aes("carat", "price"))
    + geom_point(alpha=0.08, size=0.5)
    + geom_smooth(method="lm", color="red")
    + facet_wrap("~cut", nrow=1)
    + scale_x_log10(breaks=[0.3, 1, 3])
    + scale_y_log10(breaks=[500, 2000, 10000],
                    labels=lambda l: ["${:,.0f}".format(v) for v in l])
    + labs(x="Peso (escala log)", y="Preço (escala log)", title="Preço vs. peso por corte")
    + theme_minimal()
    + theme(figure_size=(7, 3), axis_text=element_text(size=6))
)
```




```
(
    ggplot(diamonds, aes("carat", "price", color="cut"))
    + geom_smooth(method="lm", se=False)
    + scale_x_log10(breaks=[0.3, 0.5, 1, 2, 3])
    + scale_y_log10(breaks=[500, 1000, 2000, 5000, 10000],
                    labels=lambda l: ["${:,.0f}".format(v) for v in l])
    + labs(x="Peso (escala log)", y="Preço (escala log)", color="Corte",
           title="Retas ajustadas por corte")
    + theme_minimal()
    + theme(figure_size=(6, 4))
)
```




```
linhas = []
for corte, g in diamonds.groupby("cut", observed=True):
    b, a = np.polyfit(np.log10(g["carat"]), np.log10(g["price"]), 1)
    linhas.append({"cut": corte, "n": len(g), "inclinacao": round(b, 3), "intercepto": round
pd.DataFrame(linhas)
```

| | cut | n | inclinacao | intercepto |
|---|---|---|---|---|
| 0 | Fair | 1610 | 1.495 | 3.556 |
| 1 | Good | 4906 | 1.736 | 3.638 |
| 2 | Very Good | 12082 | 1.727 | 3.671 |
| 3 | Premium | 13791 | 1.657 | 3.660 |
| 4 | Ideal | 21551 | 1.707 | 3.702 |

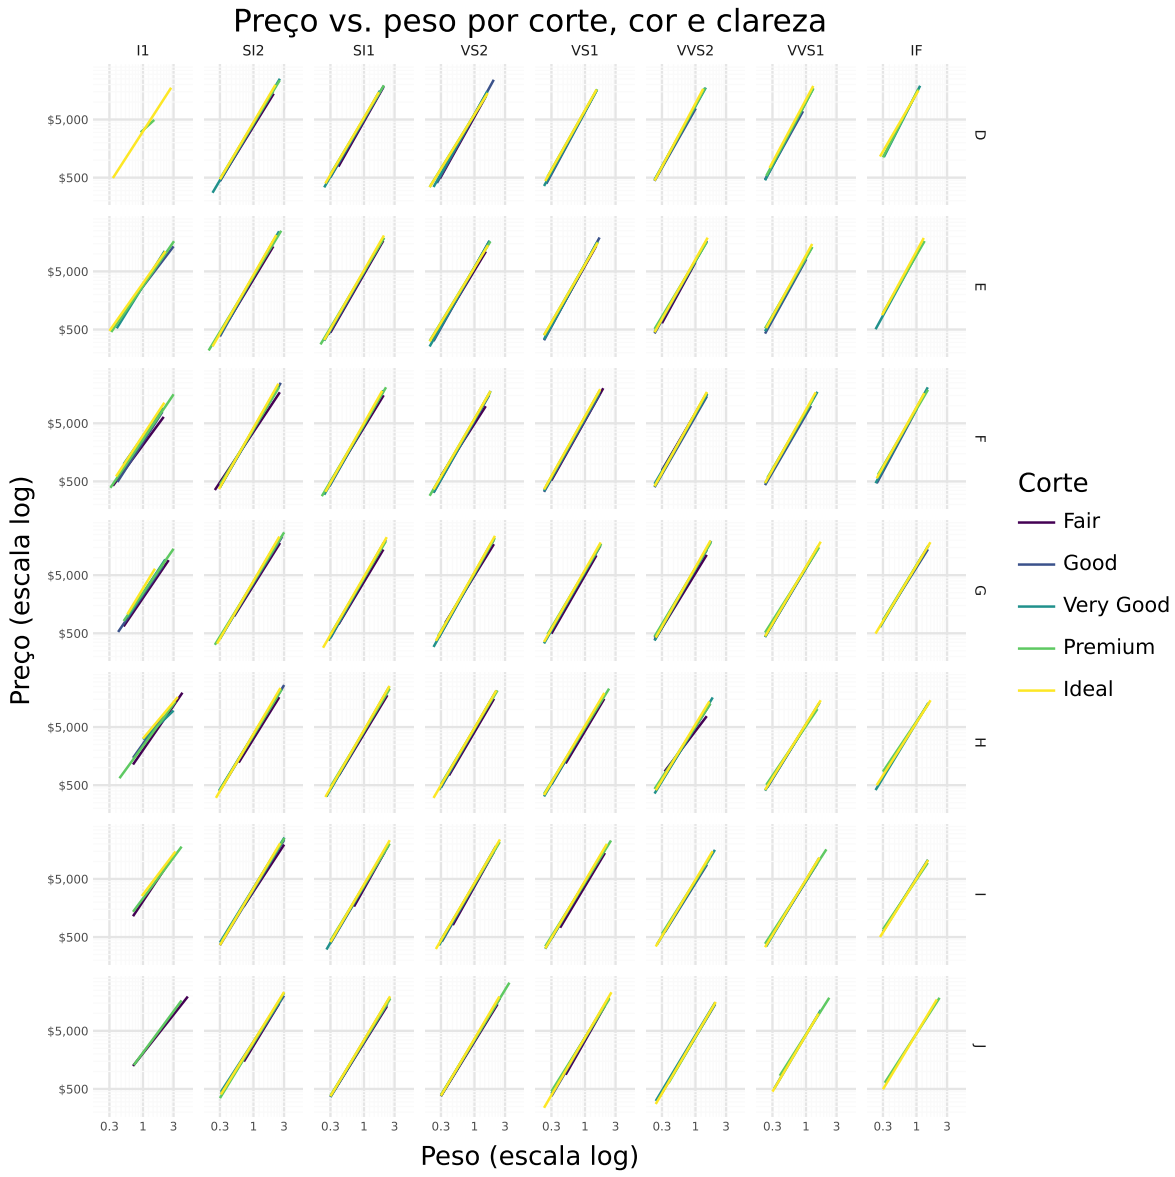
em todos os cortes a relação é positiva e aproximadamente linear na escala log-log, mas as retas diferem em nível e inclinação. Logo, a relação não é exatamente a mesma entre os cortes: o preço esperado para um dado peso depende também da qualidade do corte, embora a diferença seja modesta perto do efeito do peso.

## Questão 3

```
d3 = diamonds.copy()
d3["n"] = d3.groupby(["cut", "color", "clarity"], observed=True)["price"].transform("size")
d3 = d3[d3["n"] >= 10]
print(d3.groupby(["cut", "color", "clarity"], observed=True).ngroups, "combinações mantidas")
```

```
246 combinações mantidas
```

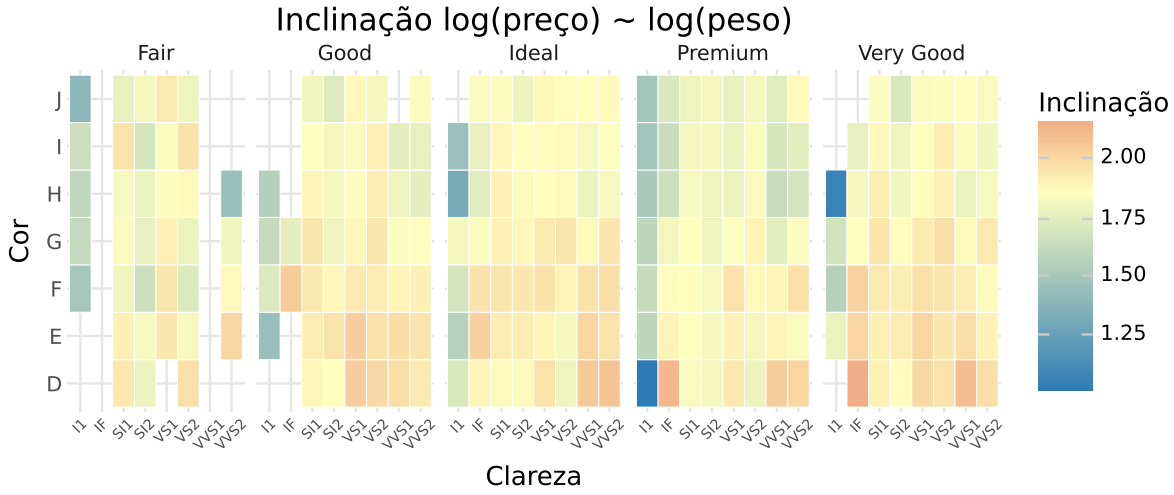
```
(
    ggplot(d3, aes("carat", "price", color="cut"))
    + geom_smooth(method="lm", se=False, size=0.6)
    + facet_grid("color ~ clarity")
    + scale_x_log10(breaks=[0.3, 1, 3])
    + scale_y_log10(breaks=[500, 5000], labels=lambda l: ["${:,.0f}".format(v) for v in l])
    + labs(x="Peso (escala log)", y="Preço (escala log)", color="Corte",
           title="Preço vs. peso por corte, cor e clareza")
    + theme_minimal()
    + theme(figure_size=(7, 7), axis_text=element_text(size=5), strip_text=element_text(size=
)
```




```
linhas = []
for (corte, cor, clar), g in d3.groupby(["cut", "color", "clarity"], observed=True):
    b, a = np.polyfit(np.log10(g["carat"]), np.log10(g["price"]), 1)
    linhas.append({"cut": corte, "color": cor, "clarity": clar, "inclinacao": b})
coefs = pd.DataFrame(linhas)

(
    ggplot(coefs, aes("clarity", "color", fill="inclinacao"))
    + geom_tile(color="white")
```

```
    + facet_wrap("~cut", nrow=1)
    + scale_fill_gradient2(midpoint=coefs["inclinacao"].median(),
                           low="#2c7bb6", mid="#ffffbf", high="#d7191c", name="Inclinação")
    + labs(x="Clareza", y="Cor", title="Inclinação log(preço) ~ log(peso)")
    + theme_minimal()
    + theme(figure_size=(7, 3), axis_text_x=element_text(rotation=45, size=6)))
```




São 280 combinações possíveis, o que gera muitos painéis; algumas combinações têm poucos diamantes e o ajuste fica instável (filtrei as com n $< 10$). Plotar todos os pontos poluiria o gráfico, então mostrei só as retas e um mapa de calor das inclinações.

Portanto, em quase todas as configurações a relação entre peso e preço é positiva e aproximadamente linear em log-log, mas o nível e a inclinação variam conforme cor, clareza e corte. Portanto a relação não é a mesma para todas as configurações: diamantes de melhor cor e clareza tendem a ser mais caros para um mesmo peso.

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```