

ME315_LAB02 - Processamento de Bases de Dados em Lote

Alessandro Silva - 236928

```
library(readr)
library(dplyr)
```

Questão 1:

Para calcular um percentual de atraso por grupo (dia, mês, companhia), não é necessário guardar todas as observações, basta, pra cada grupo, manter:

- `n_atraso`: número de voos com `ARRIVAL_DELAY > 10`;
- `n_total`: número total de voos válidos naquele grupo.

Com essas duas contagens por lote, é possível somar entre lotes e só depois calcular o percentual final, sem precisar manter os dados brutos em memória.

Questão 2:

```
getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(YEAR), !is.na(MONTH), !is.na(DAY), !is.na(ARRIVAL_DELAY)) %>%
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%
    summarise(
      n_atraso = sum(ARRIVAL_DELAY > 10, na.rm = TRUE),
      n_total  = n(),
      .groups  = "drop"
    )
}
```

Questão 3:

```
col_types_flights <- cols_only(  
  YEAR      = col_integer(),  
  MONTH     = col_integer(),  
  DAY       = col_integer(),  
  AIRLINE    = col_character(),  
  ARRIVAL_DELAY = col_integer()  
)  
  
stats_parcial <- read_csv_chunked(  
  file      = "flights.csv",  
  callback  = DataFrameCallback$new(getStats),  
  chunk_size = 100000,  
  col_types = col_types_flights  
)
```

Questão 4

```
computeStats <- function(stats_parcial) {  
  stats_parcial %>%  
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%  
    summarise(  
      n_atraso = sum(n_atraso),  
      n_total  = sum(n_total),  
      .groups  = "drop"  
    ) %>%  
    mutate(  
      Data = as.Date(sprintf("%04d-%02d-%02d", YEAR, MONTH, DAY)),  
      Perc = n_atraso / n_total  
    ) %>%  
    rename(Cia = AIRLINE) %>%  
    select(Cia, Data, Perc)  
}  
  
stats_final <- computeStats(stats_parcial)  
stats_final
```

A tibble: 1,276 x 3

```

      Cia    Data      Perc
      <chr> <date>    <dbl>
1 AA      2015-01-01 0.373
2 DL      2015-01-01 0.0847
3 UA      2015-01-01 0.289
4 US      2015-01-01 0.196
5 AA      2015-01-02 0.430
6 DL      2015-01-02 0.180
7 UA      2015-01-02 0.349
8 US      2015-01-02 0.195
9 AA      2015-01-03 0.538
10 DL     2015-01-03 0.347
# i 1,266 more rows

```

Questão 5:

```

library(ggcal)
library(ggplot2)
pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

```

```

baseCalendario <- function(stats, cia) {
  sub <- stats %>% filter(Cia == cia)
  ggcal(sub$Data, sub$Perc)
}

```

```

cAA <- baseCalendario(stats_final, "AA")
cDL <- baseCalendario(stats_final, "DL")
cUA <- baseCalendario(stats_final, "UA")
cUS <- baseCalendario(stats_final, "US")

```


American Airlines (AA)

```

cAA + pal + ggtitle("American Airlines - Percentual de atrasos na chegada (2015)")

```


American Airlines – Percentual de atrasos na chegada (2015)



Delta Airlines (DL)

```
cDL + pal + ggtitle("Delta Airlines - Percentual de atrasos na chegada (2015)")
```


Delta Airlines – Percentual de atrasos na chegada (2015)



United Airlines (UA)

```
cUA + pal + ggtitle("United Airlines - Percentual de atrasos na chegada (2015)")
```


United Airlines – Percentual de atrasos na chegada (2015)



US Airways (US)

```
cUS + pal + ggtitle("US Airways - Percentual de atrasos na chegada (2015)")
```

US Airways – Percentual de atrasos na chegada (2015)



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-24 16:11:38 -03"
```